MAT02010 - Tópicos Avançados em Estatística II

Diagaramas causais: uma introdução

Rodrigo Citton P. dos Reis
citton.padilha@ufrgs.br

Universidade Federal do Rio Grande do Sul
Instituto de Matemática e Estatística
Departamento de Estatística

Porto Alegre, 2019

O que é inferência causal?

O que é inferência causal?

- A inferência causal é a ciência de **inferir a presença e a magnitude das relações de causa e efeito a partir dos dados**.
- Como estatísticos, epidemiologistas, sociólogos, etc., e de fato como seres humanos, é algo sobre o qual **sabemos muito**.
  - Suponha que um estudo encontre uma associação entre a propriedade paterna de gravata de seda e a mortalidade infantil.
  - Com base nisso, o governo implementa um programa no qual 5 gravatas de seda são dadas a todos os homens com idade de 18-45 anos, com o objetivo de reduzir a mortalidade infantil.
- Nós todos concordamos que isso é uma bobagem!
- Isso porque entendemos a diferença entre associação e causalidade.

O que é inferência causal?

A área de inferência causal consiste em (pelo menos) três partes:

1. Uma **linguagem formal** para definir inequivocamente conceitos causais.
2. **Diagramas causais:** uma ferramenta para exibir claramente nossas suposições causais.
3. **Métodos de análise** (isto é, métodos estatísticos) que podem nos ajudar a tirar conclusões causais mais confiáveis a partir dos dados disponíveis.

Um pouco de dor de cabeça!

Um exemplo

- 12 senhoras estão sofrendo de **dor de cabeça**.
- Algumas tomam **aspirina**; outras não.
- Uma hora depois, perguntamos para cada uma delas se a dor de cabeça **sumiu (passou)**.

Os dados observados

	Z (tomou aspirina?)	R (dor de cabeça sumiu?)
Mary	0	0
Anna	1	0
Emma	1	1
Elizabeth	0	0
Minnie	0	1
Margaret	1	0
Ida	1	0
Alice	0	0
Bertha	0	1
Sarah	0	0
Annie	0	1
Clara	1	1

Os dados observados

	Z (tomou aspirina?)	R (dor de cabeça sumiu?)
Mary	0	0
Anna	1	0
Emma	1	1
Elizabeth	0	0
Minnie	0	1
Margaret	1	0
Ida	1	0
Alice	0	0
Bertha	0	1
Sarah	0	0
Annie	0	1
Clara	1	1

Os dados observados

- Emma tomou aspirina ($Z = 1$) e a sua dor de cabeça passou ($R = 1$).
- A aspirina causou o desaparecimento da sua dor de cabeça?

Relembrando

A estrutura da inferência causal:

- Z é o tratamento atribuído: tomou aspirina?
- R é o desfecho/resposta: dor de cabeça sumiu?
- r_C e r_T representam os **desfechos potenciais**.
  - r_C é a resposta que teria sido observada caso a aspirina NÃO tivesse sido tomada.
  - r_T é a resposta que teria sido observada caso a aspirina tivesse sido tomada.
- Uma destas respostas é observada: se $Z = 0$, r_C é observada; se $Z = 1$, r_T é observada.
  - Ou seja, $R = Z \times r_T + (1 - Z) \times r_C$.
  - A outra é **contrafactual**.

Os dados ideais

	r_C	r_T
Mary	0	0
Anna	1	0
Emma	0	1
Elizabeth	0	0
Minnie	1	1
Margaret	0	0
Ida	0	0
Alice	0	0
Bertha	1	0
Sarah	0	0
Annie	1	1
Clara	0	1

Os dados ideais

Com o par de desfechos potenciais, podemos responder as seguintes perguntas:

- A aspirina causou o desaparecimento da dor de cabeça de Emma?
  - E de Margaret?
  - E de Clara?
  - E de Alice?

Os dados ideais

i	r_{C_i}	r_{T_i}	$\delta_i = r_{T_i} - r_{C_i} \neq 0$? (efeito causal?)
Mary	0	0	Não
Anna	1	0	Sim, prejudicial
Emma	0	1	Sim, benéfico
Elizabeth	0	0	Não
Minnie	1	1	Não
Margaret	0	0	Não
Ida	0	0	Não
Alice	0	0	Não
Bertha	1	0	Sim, prejudicial
Sarah	0	0	Não
Annie	1	1	Não
Clara	0	1	Sim, benéfico

O problema fundamental da inferência causal

i	r_{C_i}	r_{T_i}	Z_i	R_i
Mary	0	?	0	0
Anna	?	0	1	0
Emma	?	1	1	1
Elizabeth	0	?	0	0
Minnie	1	?	0	1
Margaret	?	0	1	0
Ida	?	0	1	0
Alice	0	?	0	0
Bertha	1	?	0	1
Sarah	0	?	0	0
Annie	1	?	0	1
Clara	?	1	1	1

Efeitos causais populacionais

- $\delta_i = r_{T_i} - r_{C_i} = ?$, para todo indivíduo i, pois um dos desfechos potenciais nunca é observado.
- Um objetivo menos ambicioso é focar no **efeito causal médio** (ou em nível populacional):

$$\overline{\delta} = \overline{r}_T - \overline{r}_C.$$

- No caso em que a resposta é dicotômica, temos

$$\overline{\delta} = \Pr(r_T = 1) - \Pr(r_C = 1).$$

Efeitos causais populacionais

i	r_{C_i}	r_{T_i}	$\delta_i = r_{T_i} - r_{C_i} \neq 0$? (efeito causal?)
Mary	0	0	Não
Anna	1	0	Sim, prejudicial
Emma	0	1	Sim, benéfico
Elizabeth	0	0	Não
Minnie	1	1	Não
Margaret	0	0	Não
Ida	0	0	Não
Alice	0	0	Não
Bertha	1	0	Sim, prejudicial
Sarah	0	0	Não
Annie	1	1	Não
Clara	0	1	Sim, benéfico

- $\bar{r}_T = \Pr(r_T = 1) = 4/12$ e $\bar{r}_C = \Pr(r_C = 1) = 4/12$, e portanto,

$$\bar{\delta} = \bar{r}_T - \bar{r}_C = \frac{4}{12} - \frac{4}{12} = 0.$$

- Ou seja, **não existe** efeito causal em nível populacional.

Efeitos causais populacionais

- Em verdade, **não sabemos** r_T para cada indivíduo, então **não podemos simplesmente estimar** $\Pr(r_T = 1)$ como a proporção de todos os indivíduos com $r_T = 1$.
- Da mesma forma, **não podemos simplesmente estimar** $\Pr(r_C = 1)$ como a proporção de todos os indivíduos com $r_C = 1$.
- Assim, **não podemos estimar** facilmente $\overline{\delta} = \Pr(r_T = 1) - \Pr(r_C = 1)$ pelo mesmo motivo que não podemos estimar $\delta_i = r_{T_i} - r_{C_i}$.
- A inferência causal **é toda sobre a escolha de quantidades dos dados observados** (isto é, envolvendo Z, R e outras variáveis observadas) **que representam substitutos razoáveis** para quantidades hipotéticas tais como $\overline{\delta}$, que envolvem contrafactuais não observáveis.

Quando associção é igual a causalidade?

- O que pode ser um bom substituto para $\Pr(r_T = 1)$?
  - E quanto a $\hat{r}_T = \Pr(R = 1|Z = 1)$?
  - Esta é a proporção de "dor de cabeça desapareceu" entre aquelas que realmente tomaram a aspirina.
  - Isso é o mesmo que $\Pr(r_T = 1)$?
    - Somente se aquelas que tomaram a aspirina forem **intercambiáveis** com aquelas que não o fizeram.
- Este seria o caso se a escolha de tomar a aspirina fosse feita ao acaso.
- É por isso que **experimentos aleatorizados** são o **padrão-ouro** para inferir efeitos causais.

Quando associção é igual a causalidade?

i	r_{C_i}	r_{T_i}	Z_i	R_i
Mary	0	?	0	0
Anna	?	0	1	0
Emma	?	1	1	1
Elizabeth	0	?	0	0
Minnie	1	?	0	1
Margaret	?	0	1	0
Ida	?	0	1	0
Alice	0	?	0	0
Bertha	1	?	0	1
Sarah	0	?	0	0
Annie	1	?	0	1
Clara	?	1	1	1

- $\hat{r}_T = \Pr(R = 1|Z = 1) = 2/5$ e $\hat{r}_C = \Pr(R = 1|Z = 0) = 3/7$, e portanto,

$$\hat{\delta} = \hat{r}_T - \hat{r}_C = \frac{2}{5} - \frac{3}{7} = -\frac{1}{35}.$$

- Se assumirmos "associação = causalidade", concluiremos que a aspirina foi, em média, prejudicial.

Mas, e se . . .

. . . as senhoras com uma dor de cabeça **mais forte** (grave) fossem **mais propensas** a tomarem a aspirina?

- Neste caso, "associação $\neq$ causalidade"!

Levando em conta a gravidade

- Suponha que perguntamos a cada uma das 12 senhoras no início do estudo: **“sua dor de cabeça é forte?”**.
  - Então, poderíamos propor que, depois de levar em conta a gravidade, a decisão de tomar ou não a aspirina fosse efetivamente tomada de forma aleatória.
- Suponha que X denota a gravidade. Então, sob essa suposição, **dentro dos estratos** de X, os indivíduos expostos e não expostos podem ser **intercambiáveis**.
- Isso é chamado de **intercambiabilidade (permutabilidade) condicional** (dado X).
- Sob intercambiabilidade condicional dada X, “associação = causalidade” **dentro dos estratos** de X.

Levando em conta a gravidade

i	r_{C_i}	r_{T_i}	Z_i	R_i	X_i
Mary	0	0	0	0	1
Anna	1	0	1	0	0
Emma	0	1	1	1	0
Elizabeth	0	0	0	0	1
Minnie	1	1	0	1	0
Margaret	0	0	1	0	1
Ida	0	0	1	0	1
Alice	0	0	0	0	0
Bertha	1	0	0	1	1
Sarah	0	0	0	0	0
Annie	1	1	0	1	0
Clara	0	1	1	1	1

Estratificando por gravidade

No estrato $X = 0$:

- $\hat{r}_T = \Pr(R = 1|Z = 1) = 1/2$ e $\hat{r}_C = \Pr(R = 1|Z = 0) = 2/4$, e portanto,

$$\hat{\delta} = \hat{r}_T - \hat{r}_C = \frac{1}{2} - \frac{2}{4} = 0.$$

No estrato $X = 1$:

- $\hat{r}_T = \Pr(R = 1|Z = 1) = 1/3$ e $\hat{r}_C = \Pr(R = 1|Z = 0) = 1/3$, e portanto,

$$\hat{\delta} = \hat{r}_T - \hat{r}_C = \frac{1}{3} - \frac{1}{3} = 0.$$

- Ou seja, dentro dos estratos **não existe** efeito causal.

Exemplo da dor de cabeça: breves conclusões

- De maneira mais geral, se **existe** um efeito causal de Z em R, mas também **uma associação não-causal** devido a X, então o efeito causal será estimado com **viés**, a menos que estratifiquemos em X.
  - Este viés será chamada de **viés de confundimento** (ou viés de confusão) e X será chamada de **variável confundidora**.

Exemplo da dor de cabeça: breves conclusões

- A **intercambiabilidade condicional** é o principal critério que nos permite fazer declarações causais usando **dados observacionais**.
- Assim, precisamos identificar, se possível, um conjunto de (co)variáveis $X_1, X_2, \ldots$, de tal forma que a intercambiabilidade condicional é válida, dado este conjunto de variáveis.
- Na vida real, pode haver muitas variáveis candidatas X.
- Estes podem ser **causalmente inter-relacionados** de uma maneira **muito complexa**.
- Decidir se os indivíduos expostos e o não expostos são condicionalmente intercambiáveis, dado $X_1, X_2, \ldots$, **requer conhecimento detalhado do assunto**.
- Os **diagramas causais** podem nos ajudar a usar esse conhecimento para determinar se a intercambiabilidade condicional é válida ou não.

Introdução

Introdução

- Pesquisa empírica e relações entre variáveis.
- Modelos estatísticos.
    - Propósitos dos modelos estatísticos: predição *versus* explicação (exploratório, causalidade).
    - Modelos estatísticos: o papel das variáveis, e a relação de dependência entre estas.
- Na estatística, especificamos relações de dependência por meio de distribuições de probabilidades.

Introdução

- **Grafos:** na matemática e ciência da computação, grafos são usados para modelar objetos, representados por vértices (nós), e as suas relações, representadas por arestas.

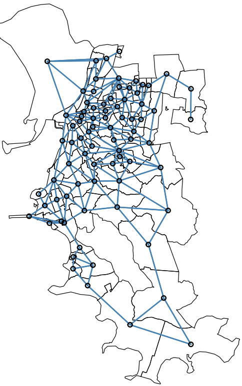

Introdução

- **DAGs:** Grafos acíclicos dirigidos (*Directed acyclic graphs*)
    - Diagramas causais
    - Modelos causais
    - Modelos gráficos
    - Modelos de equações estruturais não paramétricos
    - Modelos causais estruturais

Preliminares

Como duas variáveis podem estar associadas na população?

$$X \longrightarrow Y$$

- Duas variáveis X e Y serão **associadas** na população se X causa Y.

Como duas variáveis podem estar associadas na população?

$$X \longleftarrow Y$$

- X e Y serão associadas na população se Y causa X.

Como duas variáveis podem estar associadas na população?

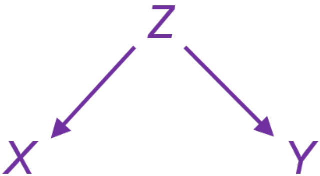

- Por fim, X e Y serão associadas na população se existir alguma variável Z que causa **ambas** X e Y.

Como duas variáveis podem estar associadas na população?

$$X \longrightarrow Y \qquad X \longleftarrow Y \qquad \begin{tikzcd} & Z \arrow[dl] \arrow[dr] & \\ X & & Y \end{tikzcd}$$

- X e Y não podem ser associadas na população por qualquer outra razão.
- Se X e Y são associadas na população, então **pelo menos uma** das situações acima deve ser verdade.

O que queremos dizer com associação “na população”?

- Na terminologia estatística, X e Y são associadas “na população” significa que estas variáveis são **marginalmente associadas**.
- Se X e Y são marginalmente associadas, então, para um indivíduo em particular, saber a respeito de X nos dá alguma informação sobre o valor provável de Y, e vice-versa.
- Suponha, por simplicidade, X e Y dicotômicas. Se X e Y são marginalmente associadas, então

$$\Pr(Y = 1|X = 1) \neq \Pr(Y = 1|X = 0)$$

e

$$\Pr(X = 1|Y = 1) \neq \Pr(X = 1|Y = 0)$$

Como duas variáveis podem estar associadas em uma subpopulação?

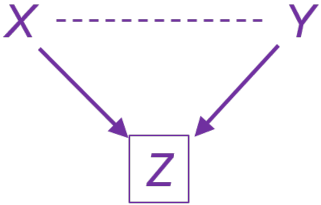

- Suponha que Z é um **efeito** tanto de X como de Y.
- Então, X e Y serão **associadas dentro do estrato de** Z, mesmo se na população estas variáveis forem independentes.
- X e Y serão condicionalmente associadas (dado Z), mesmo que sejam marginalmente independentes (não associadas).
- A caixa ao redor de Z denota que estamos estratificando (condicionando) em Z.
- A reta tracejada denota a associação condicional induzida.

Como duas variáveis podem estar associadas em uma subpopulação?

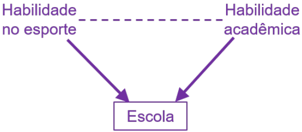

- Suponha que uma escola aceita alunos ou porque são "bons" no **esporte**, ou porque são "bons" **academicamente**; ou ainda, alunos que são "bons" nos dois.
- Suponha que a habilidade acadêmica e a habilidade no esporte sejam **independentes** na população.
- **Dentro da escola**, existirá uma associação (negativa) entre habilidade acadêmica e habilidade no esporte.
- Por que? Suponha que escolhemos um aluno ao acaso e percebemos que ele não tem habilidade nos esportes. Então, este deve ser "bom" academicamente.

Resumindo

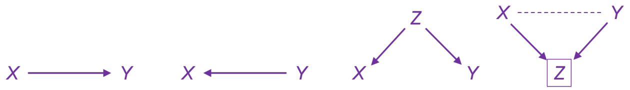

- X e Y serão **associadas na população** se:
  - X causa Y.
  - Y causa X.
  - existe uma Z que é causa comum de X e Y.
- X e Y serão **associadas em subpopulações definadas por** Z se Z é um **efeito** de X e Y.

DAGs: uma introdução mais formal

Um exemplo

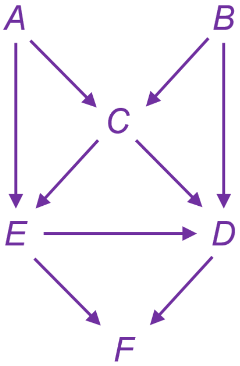

Grafo acíclico dirigido

- Este é um exemplo de um **grafo acíclico dirigido** (DAG) causal (diagrama causal).
- É **dirigido**, pois cada aresta é uma seta de ponta única.
- É **causal**, pois as setas representam nossas suposições a respeito da direção da influência causal.
- É **acíclico**, pois não contém ciclos: nenhuma variável causa a si mesma.

Terminologia

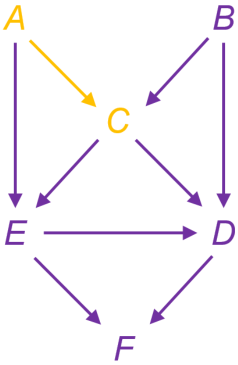

Pais e filhos

- A é **pai** (ou **mãe**) de C.
- C é **filho** (ou **filha**) de A.

Terminologia

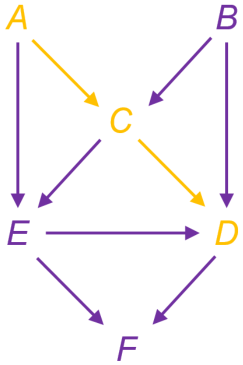

Ancestrais e descendentes

- A é um **ancestral** de D.
- D é **descendente** de A.
- A também é um **ancestral** de C.
- C também é um **descendente** de A.
  - Ou seja, pais são ancestrais, e filhos são descendentes.

Terminologia

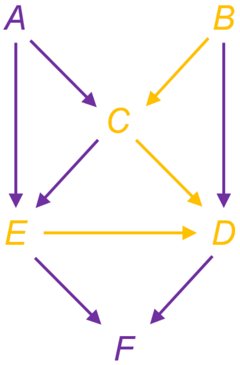

Caminho

- Este é um **caminho** de E para B.

Terminologia

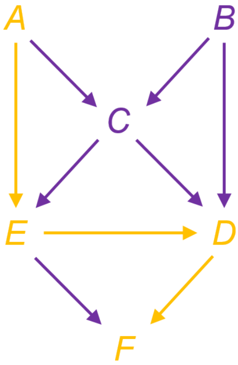

Caminho dirigido

- Este é um **caminho dirigido** de A para F (todas as setas no caminho apontam "para frente").

Terminologia

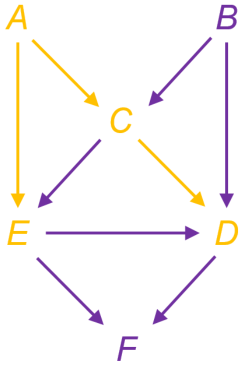

Caminho back-door

- Este é um **caminho porta dos fundos** de E para D (o caminho começa com uma seta **chegando em** E).

Terminologia

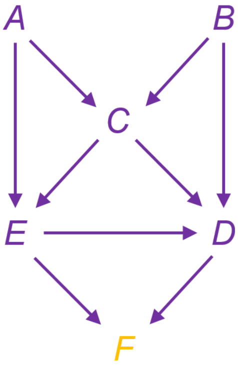

Collider

- F é um **colisor** desde que duas pontas de setas se encontram em F.

Terminologia

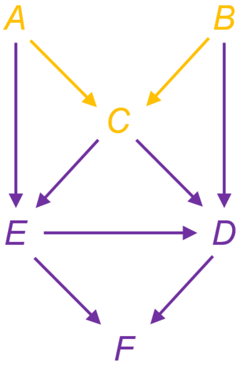

Nota

- Note que C é um colisor no caminho $A \rightarrow C \leftarrow B$.

Terminologia

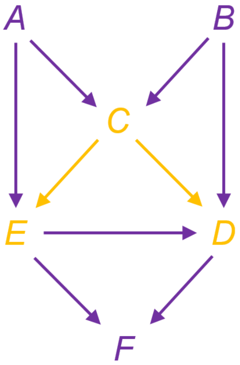

Nota

- No entanto, C NÃO É um colisor no caminho $E \leftarrow C \rightarrow D$.
- Assim, a definição de um colisor é em relação ao caminho que está sendo considerado.

Terminologia

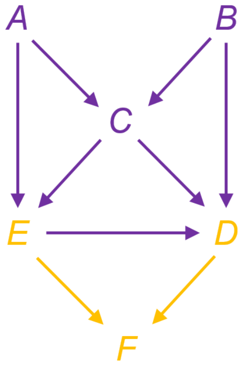

Caminho bloqueado

- O caminho $E \rightarrow F \leftarrow D$ é **bloqueado** desde que este contenha um colisor (F).

Terminologia

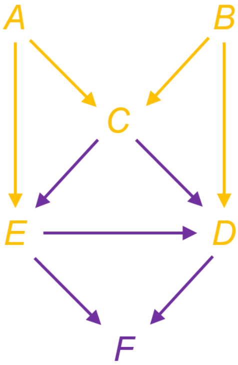

Caminho bloqueado

- Este caminho também é bloqueado (em C).

Terminologia

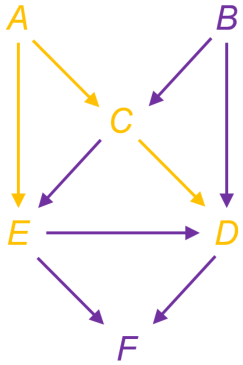

Caminho aberto

- Um caminho que não contém um colisor está **aberto**. Aqui temos um exemplo.

Terminologia

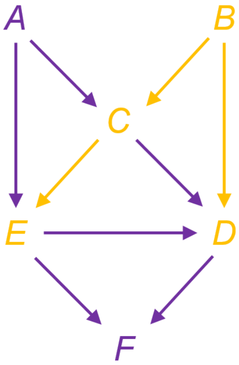

Caminho aberto

- E outro.

Terminologia

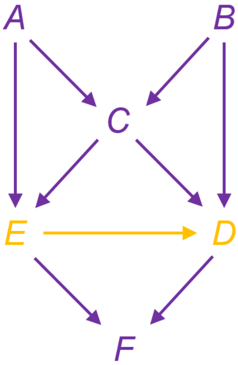

Caminho aberto

- E outro.

Construindo um DAG

$$E \longrightarrow D$$

Passo 1

- O primeiro passo na construção de um DAG para um problema particular é escrever a **exposição** e o **desfecho** de interesse, com uma seta da exposição para o desfecho.
- Esta seta representa o **efeito causal** que queremos estimar.

Construindo um DAG

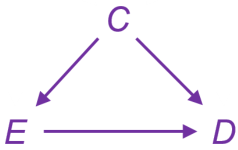

Passo 2

- Se existir qualquer **causa comum** C de E e D, devemos colocá-lo no grafo, com setas de C para E e de C para D.
- Devemos incluir C no grafo, independentemente deste ter sido ou não mensurado em nosso estudo.

Construindo um DAG

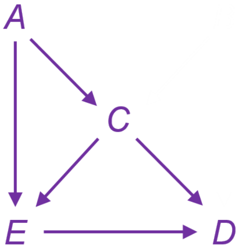

Passo 3

- Continuamos assim, adicionando ao diagrama qualquer variável (observada ou não observada) que é uma **causa comum** de duas ou mais variáveis já existentes no diagrama.

Construindo um DAG

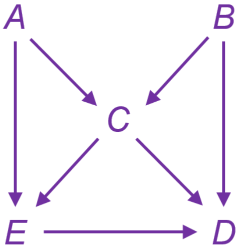

Passo 3

- Continuamos assim, adicionando ao diagrama qualquer variável (observada ou não observada) que é uma **causa comum** de duas ou mais variáveis já existentes no diagrama.

Construindo um DAG

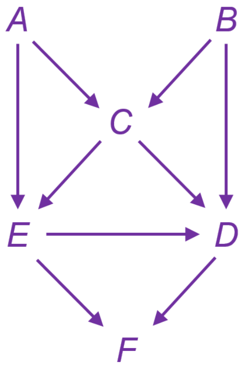

Passo 3

- Se quisermos, podemos também incluir **outras variáveis**, mesmo que eles não sejam causas comuns de outras variáveis no diagrama.
- Por exemplo, F.
- Vamos supor que finalizamos nesse ponto. As variáveis e setas que NÃO estão em nosso grafo representam nossas **suposições causais**.

Construindo um DAG

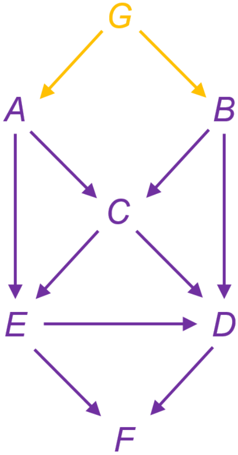

Quais são as nossas suposições?

- Por exemplo, estamos fazendo a suposição que não há uma causa comum G de A e B.

Construindo um DAG

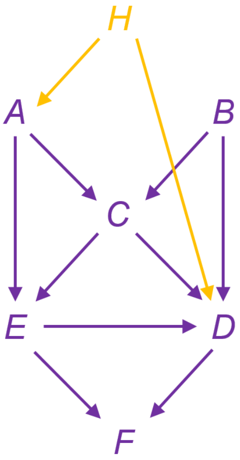

Quais são as nossas suposições?

- E que não há uma causa comum H de A e D.

Construindo um DAG

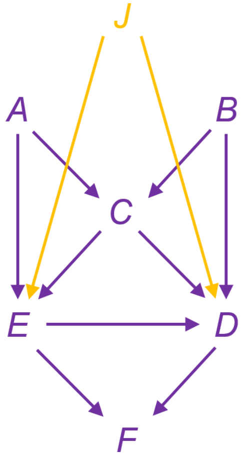

Quais são as nossas suposições?

- E que A, B e C representam TODAS as causas comuns de E e D; não há uma causa comum adicional J.

Construindo um DAG

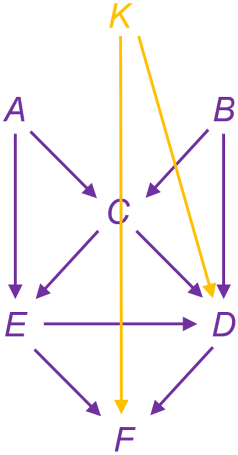

Quais são as nossas suposições?

- E que não há uma causa comum adicional K de D e F.

Construindo um DAG

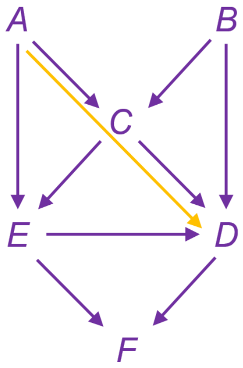

Quais são as nossas suposições?

- Portanto, cada seta omitida também representa uma suposição.
- Por exemplo, estamos assumindo que todo o efeito de A em D atua por meio de C e E.

O critério back-door: existe confundimento?

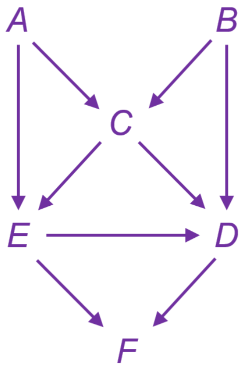

Qual o próximo passo?

- **SE** acreditarmos em nosso diagrama causal, podemos proceder para determinar se a relação $E \rightarrow D$ está **confundida** ou não.
- Isto é feito utilizando o **critério porta dos fundos**.
- O critério porta dos fundos é aplicado em duas partes:
  1. a primeira parte define se existe ou não confundimento.
  2. se existir, a segunda parte determina se é possível controlar o confundimento.

O critério back-door: existe confundimento?

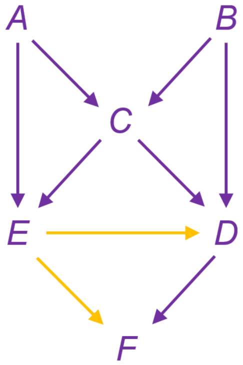

Passo 1

- Primeiro removemos todas as setas **saindo da exposição**.

O critério back-door: existe confundimento?

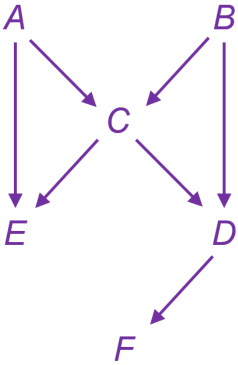

Passo 2

- Em seguida, procuramos por caminhos abertos a partir da exposição até o desfecho.
- Relembrando: um caminho aberto não contém um colisor.

O critério back-door: existe confundimento?

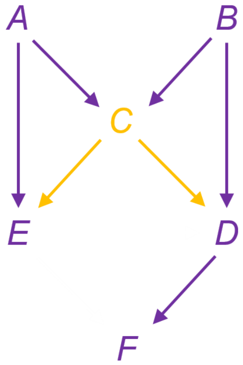

Passo 2

- Este é um caminho aberto?

O critério back-door: existe confundimento?

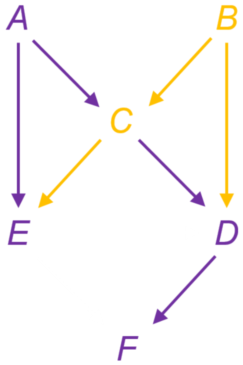

Passo 2

- Este é um caminho aberto?

O critério back-door: existe confundimento?

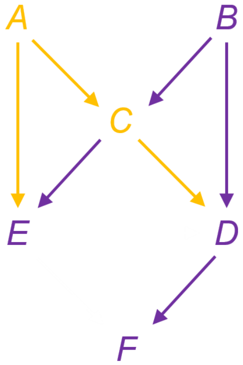

Passo 2

- Este é um caminho aberto?

O critério back-door: existe confundimento?

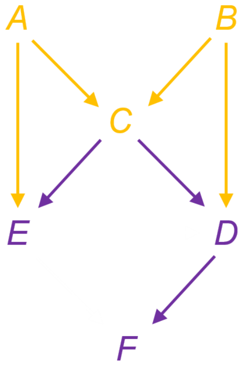

Passo 2

- Este é um caminho aberto?

O critério back-door: existe confundimento?

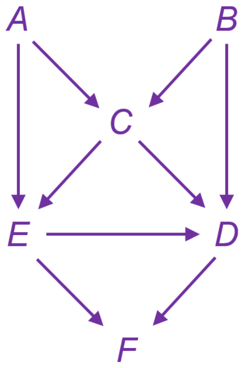

Existe confundimento?

- Identificamos três caminhos porta dos fundos abertos de E para D. Assim, há confundimento.
- Próxima pergunta: podemos usar alguns ou todos de A, B, C, F para controlar esse confundimento?
- Existe um conjunto $\mathcal{S}$ de variáveis tal que se estratificarmos (ajustarmos) por elas, podemos concluir que o efeito causal existe no estrato?

O critério back-door

A segunda parte do critério da porta dos fundos nos permite determinar, com base em nosso diagrama causal, se um conjunto de covariáveis candidato é ou não suficiente para controlar o confundimento:

O critério back-door

(i) Primeiro, o conjunto candidato $\mathcal{S}$ não deve conter **descendentes da exposição**.

(ii) Em seguida, removemos todas as setas que saem da exposição.

(iii) Então, nós **juntamos com uma linha tracejada** quaisquer duas variáveis que compartilham um filho que esteja ela mesma em $\mathcal{S}$ ou que tenha um descendente em $\mathcal{S}$.

(iv) Existe um caminho aberto de E para D que não passa por um membro de $\mathcal{S}$?

Se NÃO, então $\mathcal{S}$ é **suficiente** para controlar para confundimento.

O critério back-door: podemos controlar o confundimento?

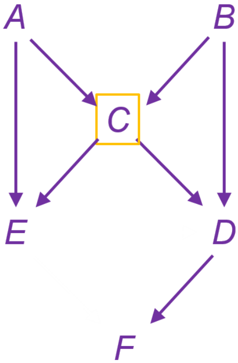

O critério back-door: passos (i) e (ii)

- *C* é suficiente?
- *C* não é um descendente de *E*, então o passo (i) é satisfeito.
- Todas as setas saindo da exposição já foram removidas (passo (ii)).

O critério back-door: podemos controlar o confundimento?

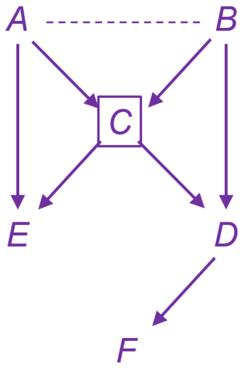

passo (iii)

- **Conectamos** A e B com uma linha tracejada, pois eles compartilham um filho (C) que está em nosso conjunto candidato (C).
- Nenhuma outra variável precisa ser conectada desta forma.

O critério back-door: podemos controlar o confundimento?

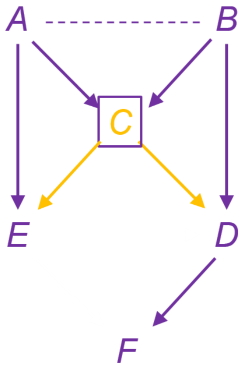

passo (iv)

- Agora procuramos por caminhos abertos de E para D e vemos se estes todos passo por C.
- Este está OK!

O critério back-door: podemos controlar o confundimento?

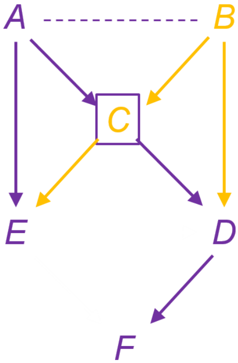

passo (iv)

- Este também!

O critério back-door: podemos controlar o confundimento?

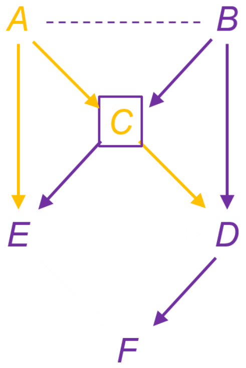

passo (iv)

- Este também!

O critério back-door: podemos controlar o confundimento?

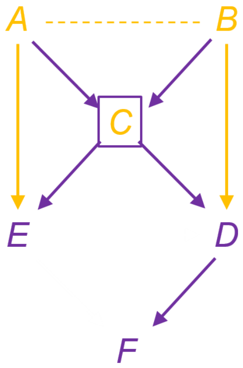

passo (iv)

- PORÉM, aqui está um caminho aberto de E para D que NÃO passa por C
- Assim, controlar apenas por C NÃO é suficiente.

O critério back-door: podemos controlar o confundimento?

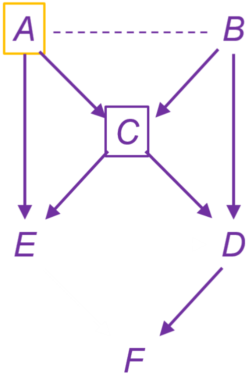

Qual é a solução?

- Devemos controlar adicionalmente para A.

O critério back-door: podemos controlar o confundimento?

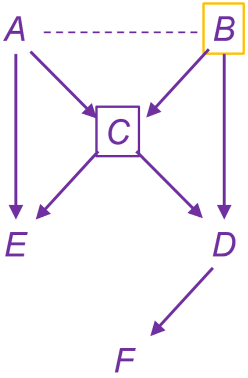

Qual é a solução?

- Ou B.

O critério back-door: podemos controlar o confundimento?

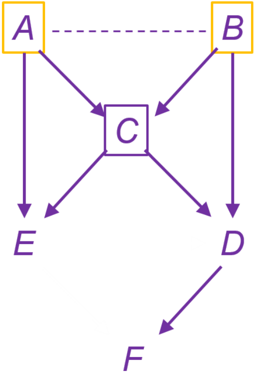

Qual é a solução?

- Ou ambos A e B para controlar para o confundimento.

Avisos

Avisos

- **Próxima semana (06/11):**
  1. Catecolaminas: diagramas causais na pesquisa empírica (**Atividade de avaliação**).
  2. Ferramentas computacionais na construção de diagramas causais.
- **Para casa:** Ler o artigo **"Causal diagrams for epidemiologic research"** de Sander Greenland, Judea Pearl e James Robins.

Por hoje é só!